امیرحسین احمدی ۹۷۵۲۲۲۹۲ – تمرین چهارم

۱- در حالت کلی adam و کلا optimizer های adaptive خیلی سریع تر از sgd خالی همگرا میشوند و برای استفاده در شبکه های عصبی پیچیده و عمیق مناسب هستند. ولی با ازمایشات انجام شده، مشاهده میشود که عملکرد sgd (منظور نسخه های مختلف sgd است) در دیتای ولیدیشن بهتر از حتی adam است و در بسیاری از مقالات معروف از sgd به عنوان optimizer اصلی استفاده میشود ولی در دیتای ترین همچنان adaptive optimizer ها عملکرد بهتری دارند. نمونه ای از آزمایش انجام شده روی یک دیتاست(سمت راست برروی ولیدیشن و چپ بر روی ترین است):

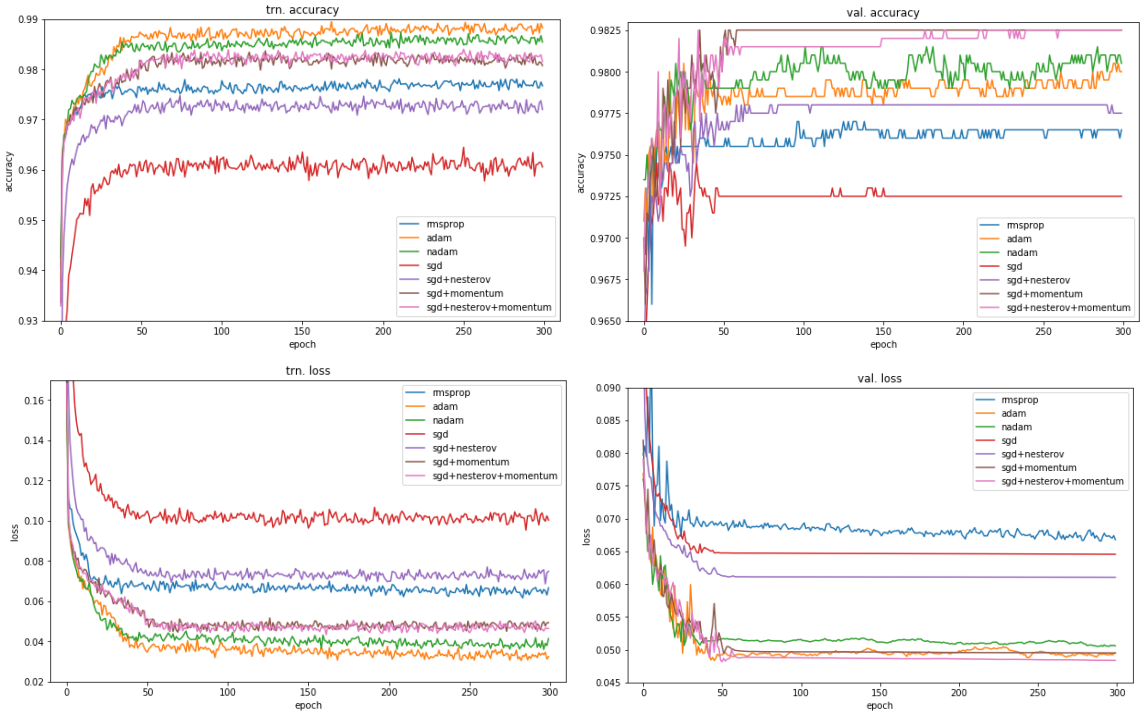

۲- در ابتدا شبکه را به صورت زیر باز کرده (هر نورون را به ضرب و جمع تجزیه کرده به غیر از تابع فعال ساز نورون آخر که بصورت مستقیم آن را حساب کردم) تا محاسبات راحت تر باشد. وزن های اولیه را نیز به صورت رندوم به صورت زیر تایین کردیم:

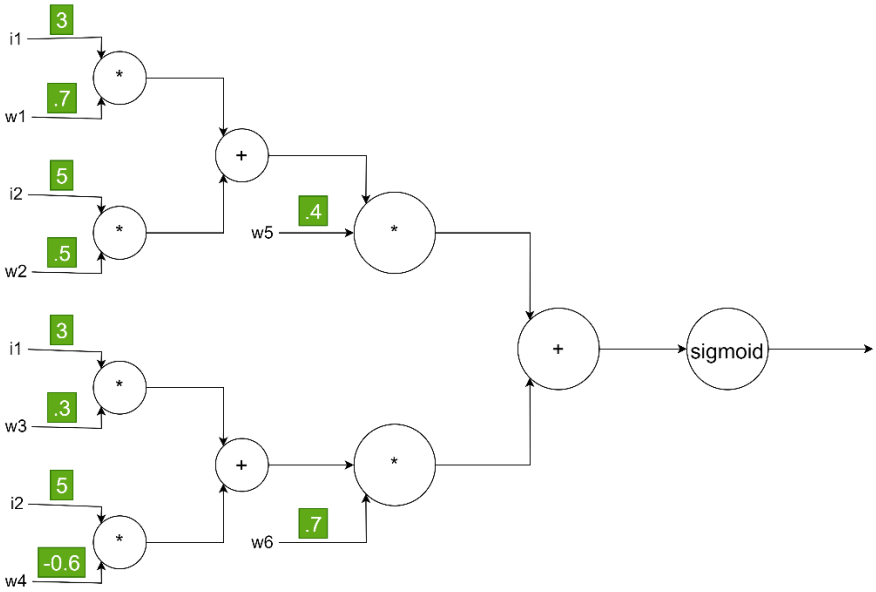

سپس برای epoch اول، برای هر نورون به ترتیب مقدار خروجی را بدست میاوریم که مقادیر در شکل زیر آورده شده و در آخر loss را با استفاده از mse بدست آورده ایم که برابر با 0.1681 شد.

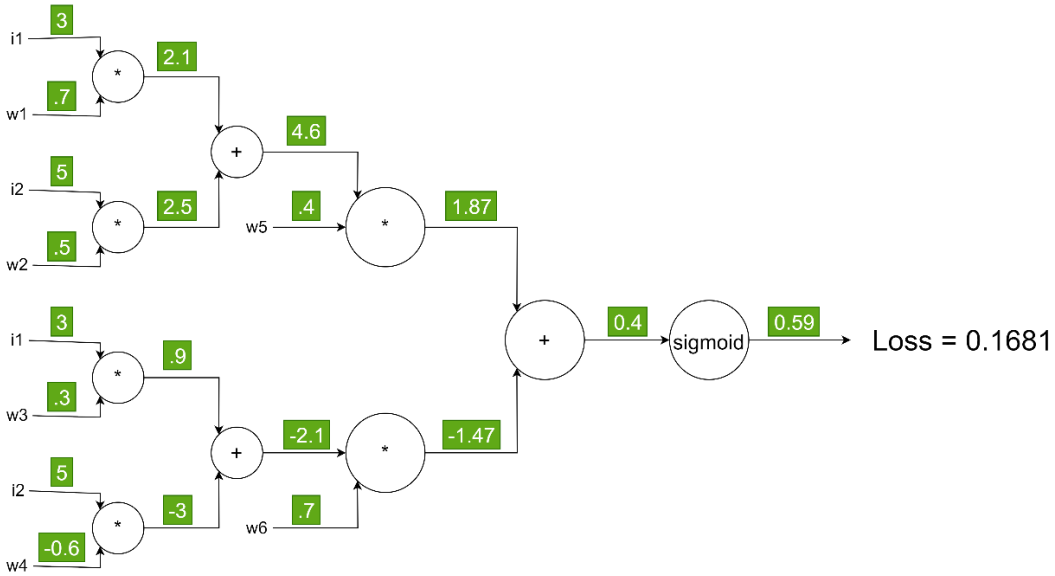

حال با استفاده از الگوریتم بک backpropagation مقدار خطا را برای هر کدام از نورون ها به صورت زنجیره ای بدست میاوریم.

در ابتدا مشتق تابع loss را نسبت به خروجی تابع sigmoid بدست میاوریم. با توجه به اینکه در این مسئله فقط یک دیتا ورودی داریم، تابع لاس به صورت رو به روست:

$$MSE = \left(Y - \hat{Y}\right)^2$$

که مشتق آن نصبت به y هت به صورت زیر بدست میاید:

$$-2 * \left(Y - \hat{Y}\right) = -2 * (1 - 0.59) = -0.82$$

در قدم بعدی باید مشتق تابع سیگموید را نسبت به z بگیریم که در تمرین ۲ بدست آورده بودیم، به صورت رو به رو بدست میاید:

$$Sigmoid = \frac{1}{1 + e^{-z}} \rightarrow \frac{\delta S(z)}{\delta z} = S(z) * \left(1 - S(z)\right) = 0.59 * (1 - 0.59) = 0.2419$$

حال اگر بخواهید مشتق لاس را نسبت به z بدست بیاوریم، طبق قاعه زنجیره ای باید مشتق لاس نسبت به سیگموید را ضرب در مشتق سیگموید به z کنیم که برابر با 0.198358- میشود که به طور تقریبی برابر با *0.19*- در نظر میگیریم. بعد از این دو نورون، کار آسون میشود، برای نورون های جمع، جواب مشتق برابر همان عدد قبل میشود و برای ضرب، نورون های ورودی به صورت برعکس ضرب میشوند. مثال:

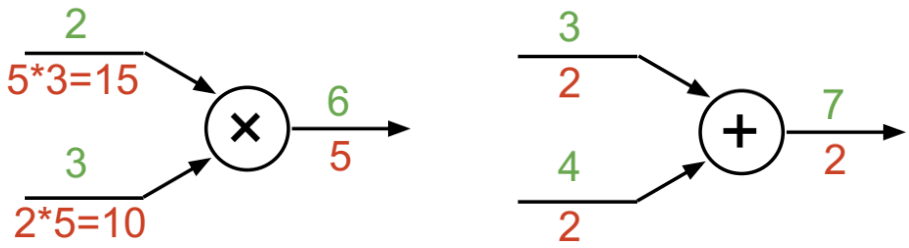

به همین ترتیب خطای مربوط به هرکدام از نورون ها را بدست آوردیم که در شکل زیر مشاهده میکنید:

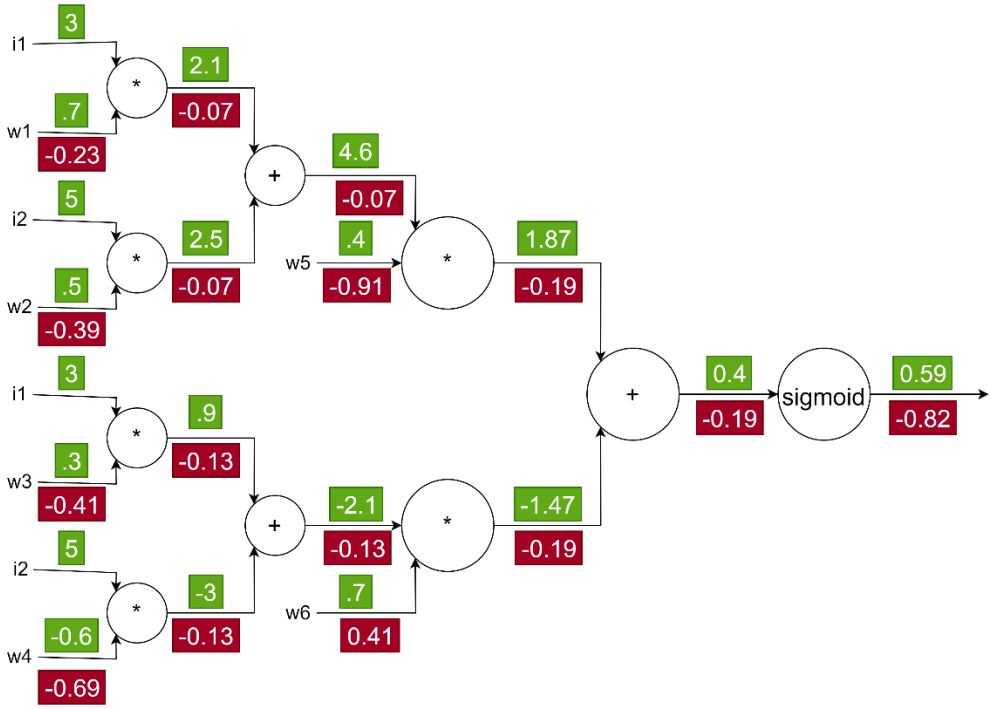

حال میخواهیم وزن هارا با توجه به مقدار خطا و با استفاده از روش گرادیان آپدیت کنیم. نرخ یادگیری را برابر با ۰.۱ در نظر میگیرم. وزن ها به صورت زیر آپدیت میشوند:

$$W_i = W_i - lr * (loss)$$
$$W_1 = .7 - 0.1 * (-0.23) = 0.72$$

بقیه w ها را نیز به صورت بالا آپدیت میکنیم. در ادامه نیز وارد $epoch$ ۲ شده و دوباره مانند قبل خروجی هر نورون را بدست میاوریم. $Epoch$ ۲ با استفاده از w های آپدیت شده در شکل زیر قابل مشاهده است:

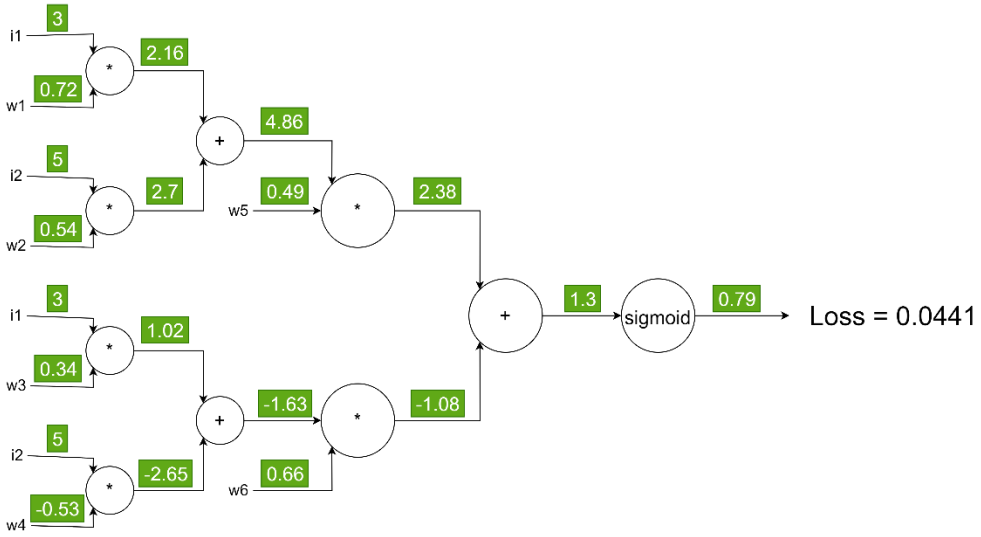

حال باید برای $epoch$ ۲ الگوریتم $backpropagation$ را اجرا کنیم که محاسبه مانند مرحله ی قبل است و خروجی را در زیر میبینیم:

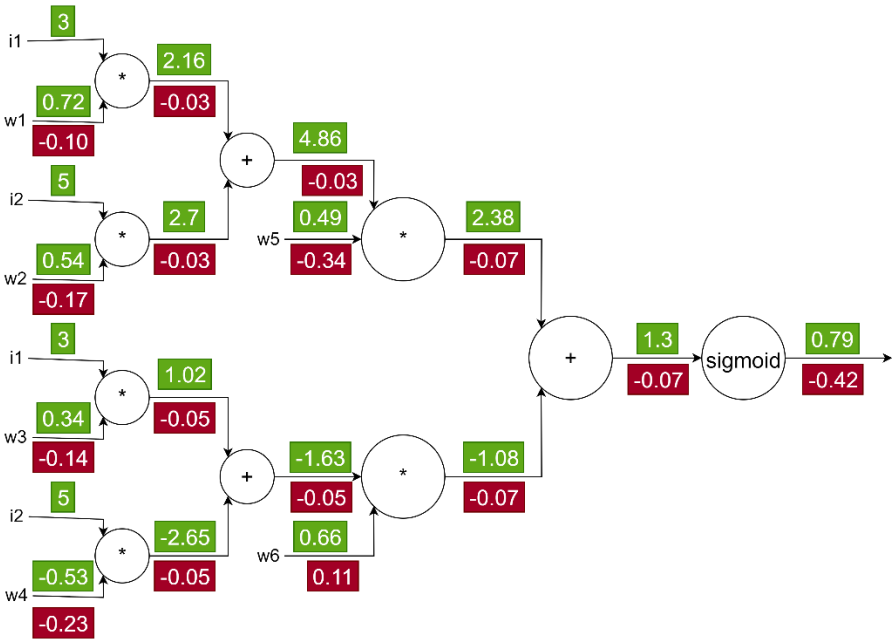

وزن ها را آپدیت کرده و برای آخرین بار لاس را حساب میکنیم:

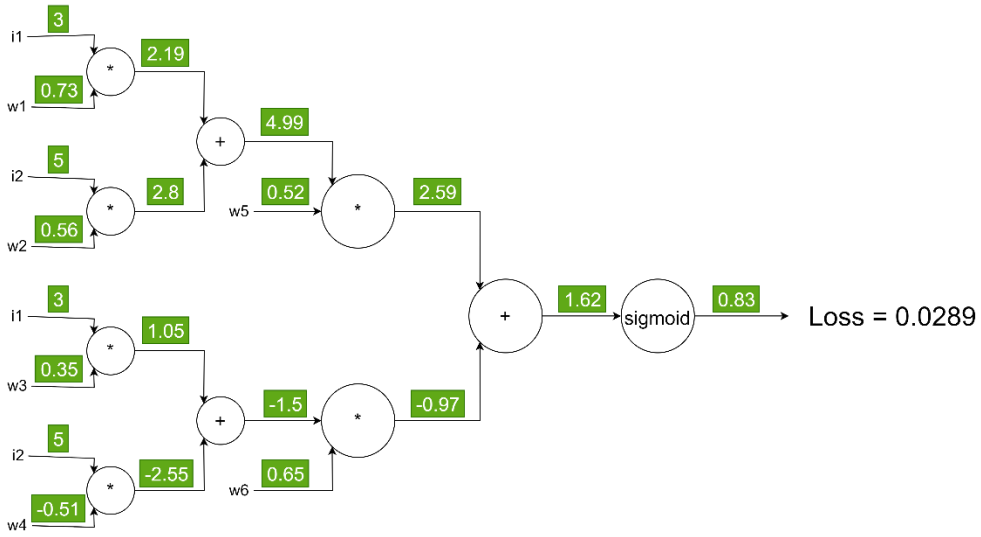

همانطور که مشاهده شد، لاس در *epoch* اول برابر با ۰.۱۶ ، در *epoch* دو برابر با ۰.۰۴ و در *epoch* سوم برابر با ۰.۰۲ شد که نشان میدهد الگوریتم به درستی دارد بهینه میکند و لاس در هر *epoch* پایین میاید. درضمن مشاهده میکنیم که فاصله ی لاس در *epoch* اول و دوم نسبت به *epoch* دوم به سوم بیشتر است که میتوان نتیجه گرفت که شیب کم شده و الگوریتم به سمت همگرایی میرود.

۳- در ابتدا و بعد از *import* ها تنظیمات مورد نیاز برای مدل را مقدار دهی کرده ایم و همچنین چک میشود که آیا *gpu* در دسترس است یا خیر.

در ادامه دیتا ها را از ورودی گرفته و ترنسفورم هایی مانند نرمالایز کردن را روی آن ها اجرا میکنیم. برای ترنسفورم دیتای *train* ترنسفورم های *RandomCrop*، *RandomHorizontalFlip* را نیز علاوه بر ترنسفورم های مربوط به نرمالایز کردن و تنسور کردن را اضافه کردیم که به ترتیب، قسمت هایی از تصاویر را برش میدهد تا پدینگ ۴ و دومی نیز به صورت افقی و رندوم تصویر را میچرخواند که باعث این ترنسفورم ها باعث اضافه شدن دیتای ورودی شده و از با بالا رفتن نویز تصاویر، احتمال اور فیت شدن مدل کمتر میشود. و در ادامه نیز تعدادی از داده های *train* را به همراه لیبلشان نمایش داده ایم.

برای ساخت مدل، در لایه های *conv2d* ابعاد چنل را دو برابر میکنیم ولی ابعدا تصویر ثابت میماند. در لایه های *MaxPool2d* چنل وردی ثابت نگه میداریم و ابعاد را نصف میکنیم. (*stride = 2*) در آخر

(*fc_layer*) نیز سه لایه با ابعاد ۵۱۲، ۲۵۶ و ۱۰ برای دسته بندی قرار میدهیم. برای همه ی لایه های *dropout* احتمال را برابر با ۰.۰۵ در نظر گرفتیم.

برای تابع ضرر و *optimizer* نیز همانطور که گفته شد به ترتیب از *croos entropy* و *adam* استفاده شده است که لرنینگ ریت را برابر با ۰.۰۰۱ قرار دادیم.

حال به ازای هر *epoch* روی *trainloader* که داده ها را به صورت *batch* های ۱۲۸ تایی (در ابتدا مشخص کردیم) به ما میدهد، فور میزنیم. در صورت استفاده از *gpu* داده ورودی را برای استفاده از آن در نظر میگیریم. سپس دیتای *train* را به مدل داده و به صورت *forward* حرکت میکنیم، بعد لاس را محاسبه کرده و در آخر مقادیر *adam* را صفر میکنیم و با مقدار جدید *loss* وزن ها را آپدیت میکنیم. در انتهای فور به اضای یک مقدار خاص از ایتریشن ها، مقدار لاس را خروجی میدهیم.

در سل آخر نیز به ازای هر لیبل دقت آن را محاسبه میکنیم که با توجه به کم بودن *epoch* ها نتایج خوبی دست نیامد.

منابع:

https://androidkt.com/convolutional-neural-network-using-sequential-model-in-pytorch/

https://pytorch.org/tutorials/beginner/blitz/cifar10_tutorial.html

https://zhenye-na.github.io/2018/09/28/pytorch-cnn-cifar10.html#loss-training-accuracy-and-test-accuracy

https://pytorch.org/vision/stable/transforms.html

https://modelzoo.co/model/data-augmentation-and-sampling-for-pytorch